

2026 新北市 AI 智慧城市黑客松 · 交通局命題 · 項目二 數據及資料運用

# 資料預處理 從 TDX 原始檔到訓練資料集

589 天逐日 CSV，經落地、守門、30 分格點化與日曆特徵，  
成為 SageMaker DeepAR 的 1,528 條訓練序列。  
每一段都附「為什麼這樣做」與「不這樣做會怎樣」。

# 資料清理目錄

一條管線七段，**每段只做一件事**—— 落地、守門、格點、日曆、特徵、匯出，外加一條旁支。


| 段  | 腳本                                        | 產物                              | 一句話                     |
|----|-------------------------------------------|---------------------------------|-------------------------|
| 落地 | meet/20260817/lab/44_load_tdx_raw.sh      | tdx_raw_station / tdx_raw_avail | 全欄位 TEXT，一列都不丟          |
| 守門 | ml-deepar/sql/baseline_create_import.sql  | public.baseline                 | 逐筆保留，只標記合法性             |
| 格點 | ml-deepar/sql/baseline_resample_export.sh | public.baseline_grid            | 重取樣成 30 分等距序列           |
| 日曆 | ml-deepar/sql/dim_calendar.sql            | public.dim_calendar             | 一天一列，產 is_holiday       |
| 特徵 | ml-deepar/sql/trainset_view.sql           | public.trainset_v               | VIEW，接上日曆               |
| 匯出 | ml-deepar/sql/export_sagemaker_jsonl.sh   | data/sagemaker_demo2604/        | 兩個 channel 的 JSON Lines |
| 旁支 | ml-deepar/sql/station_profile.sql         | public.station_profile          | 站名／行政區／座標               |

|                                                      |                                                       |                                                  |
|------------------------------------------------------|-------------------------------------------------------|--------------------------------------------------|
| <b>589 天</b><br>TDX 兩組逐日 CSV，2025-01-01 ~ 2026-08-12 | <b>26,507,021 列</b><br>baseline_grid，1,587 站 / 3.4 GB | <b>1,528 站</b><br>train 1,528 條序列、test 181,594 條 |
|------------------------------------------------------|-------------------------------------------------------|--------------------------------------------------|

# 血緣關係總覽

## 資料血緣 TDX 原始檔 → DeepAR 訓練資料集

左→右為資料流向。框內第二行是落地的表或檔，邊上的字是那一步做的事；重取樣的三條規則見右下註記。



### 重取樣的三條規則（決定序列長什麼樣）

- ① 每站每格取格內最後一筆 —— 預測標的是那一刻的水位，平均值是不存在的狀態
- ② 缺格 carry-forward，連缺 6 格（3 小時）以上留 null —— 長空窗硬填會造出一條假的水平線
- ③ 每站的骨架只長到自己實際有回報的區間 —— 站點上線前不補假 null

圖中每個節點都是實際存在的表或檔，不是概念示意。上游中間層 baseline／station\_profile 已清理，庫裡只剩 baseline\_grid 與 dim\_calendar。

# 資料來源清單

只有**三個來源**，全部是官方公開資料。TDX＝交通部運輸資料流通服務平臺（前身 PTX），需申請金鑰後呼叫。

SOURCE 01 TDX

## 站位 BikeStation

StationUID、站名、座標、總柱數。  
逐日一份版本，落檔 589 個 CSV。

raw/importdata/UBike/新北市/  
新北市自行車租借站位歷史資料/

SOURCE 02 TDX

## 車況 BikeAvailability

可借車數、可還空位、營運狀態。  
逐筆回報，落檔 589 個 CSV。

raw/importdata/UBike/新北市/  
新北市公共自行車站點剩餘數量歷史資料/

SOURCE 03 人事行政總處

## 辦公 日曆表

113~116 年，一天一列。  
唯一用途是產出 is\_holiday。

raw/importdata/假日:行事曆/

兩組 TDX 資料各附一份「欄位說明.md」。落檔範圍 **589 天（2025-01-01 ~ 2026-08-12）**，官方歷史可回溯至 2021-01-21 —— 也就是這條管線的可擴充上限。

# 資料源選型

兩個候選，採 **TDX**，不做兩源合併。

|             | 主辦 12 個 CSV (2026-01~06) | TDX 歷史資料 ✓ 採用           |
|-------------|--------------------------|-------------------------|
| 編碼          | cp950／utf-8 混雜，6 站站名亂碼   | 全 UTF-8，零亂碼             |
| 結構          | 單一寬表，站點屬性逐列重複            | 車況與站位分離，靠 StationUID 關聯 |
| 區間          | 6 個月                     | 19 個月                   |
| 非營運站        | 只能從數值反推                  | 車況表不收錄，可直接判定            |
| 容量變更 / 車種拆分 | 無                        | 有                       |
| 原始粒度        | 已壓成單值，不可回復               | 保留，聚合方式可事後調整            |

亂碼那條有實際後果。BIG5 無對應碼位的站名變成？（瓦?截流站、金城?廷街口），使同一個實體站被拆成兩個站名，各自呈現 **50.85%** 的假缺漏率。未察覺就會直接污染訓練資料與缺漏率統計。

**代價要一起講。**TDX 的格點覆蓋率低於主辦，且逐月差異極大——baseline\_grid 的 is\_observed 從 2025-08 的 **44.7%** 掉到 2026-02 的 **20.9%**，2026-04 之後回到約 **64%**。這是選 TDX 換來的帳，處理方式見 P08 規則 2 與 P16 ①。

# 日曆檔選型

四份日曆檔，**只有一組能用**。

| 檔                               | 結構                              | 判定（對訓練區間 365 天）  |
|---------------------------------|---------------------------------|------------------|
| 中華民國政府行政機關辦公日曆表/{113~116}年*.csv | 每年 365~366 列， <b>一天一列</b>       | ✓ 覆蓋 365 / 365 天 |
| 政府行政機關辦公日曆表.csv                 | 1,200 列，2018~2027， <b>只列例外日</b> | ✗ 同區間只有 121 天    |
| 台北市政府行政機關辦公日曆表102年至116年.csv     | 1,802 列，2013~2028，只列例外日         | ✗ 同區間只有 122 天    |

is\_holiday = (週末 **AND NOT** 補班日) **OR** (平日 **AND** 國定假日)  
值取自原始檔的「是否放假」欄，等同官方定義，並非自行推算。

**不這樣做會怎樣**。用只列例外日的檔直接 join，365 天裡有 **243 天**會是 NULL。把 NULL 當成上班日，就會漏掉**補班的週六**——而補班日恰好是這份資料唯一無法從日期推算出來的價值。漏掉它，這個特徵就白做了。

# 落地與守門

前兩層**不做任何清洗**——一層負責「一列都不丟」，一層負責界定「哪些是可信的原始觀測」。

① 落地 RAW tdx\_raw\_station / tdx\_raw\_avail

- 1 全欄位 TEXT —— 不轉型、不清洗
- 2 每列帶 raw\_id / source\_file / source\_row —— 可回溯到原始檔第幾行
- 3 一列都不丟 —— 欄位數不符的列進 tdx\_raw\_reject，數量記進 tdx\_load\_manifest
- 4 不預先聚合 —— 格點大小的決定權留給下游

匯入時就轉型的話，格式壞掉的列會讓整批 COPY 失敗，於是被迫在進庫前先清洗——而清洗掉的東西就查不回來了。轉型失敗本身是要調查的問題。

② 守門 GATE public.baseline

- 1 一列 raw 對一列表 —— 逐筆保留、不重取樣、不補缺格
- 2 時間與數值的格式合法性記在 is\_observed
- 3 src\_update\_time\_raw 保留原始字串，另存轉好的台北時間 src\_ts（守門沒過時為 NULL）
- 4 主鍵直接沿用原始列的 raw\_id，一對一可追溯

清洗與重取樣混在同一步，日後想把格點從 30 分改成 15 分，就得從 CSV 整條重跑。CSV 拉進 DB 用 SQL 處理是本專案選定的工作方式——千萬列級聚合在 DB 端幾分鐘完成。

⚠ 站位表不可單獨重載。bigserial 會重新編號，車況表指向站位的外鍵會全部指錯。兩組一律一起載，腳本不提供只載站位的模式。

不這樣做會怎樣。出現異常值時，無法回答「這筆原本長什麼樣」。四條紀律留著，才有這一行可以打——`sed -n '<source_row>p' <source_file>`，從庫裡的任何一列直接翻回原始 CSV 的那一行。

# 格點化規則

DeepAR 要等距序列，**TDX 的回報不等距** —— 這一層負責補上落差，是整條管線裡取捨最密集的一段。

RULE 01

## 每站每格取「格內最後一筆」

- ✗ 格內取平均
- ✓ 格內取最後一筆

預測標的是「那一刻站上有幾台車」。半小時內回報三次 5 / 8 / 6 台，取平均得到 6.33 台 —— 這個數字在現實中從未出現過。取最後一筆得到 6 台，是格點結束時的真實水位。

RULE 02

## 缺格 carry-forward 連缺 6 格以上留 NULL

- ✗ 全部 carry：長空窗產生假的水平線
- ✗ 全部 NULL：短缺口本可推定，浪費資料
- ✓  $\text{carry} \leq 6$  格（3 小時）

六月實測間隔分布：81.2% 無空窗、9.3% 缺 1 格、5.1% 缺 2~3 格、4.4% 缺 4 格以上。  
DeepAR 的 target 原生支援 null —— **留白比造假便宜。**

RULE 03

## 骨架只長到自己實際有回報的區間

站點上線前不補假 null。  
  
DeepAR 官方文件明載各序列的 start 與長度可以不同，所以新站短序列是合法輸入。補齊到同一起點等於告訴模型「這個站當時存在但沒車」，與事實不符。

|                                    |                                                                              |                           |                         |                    |
|------------------------------------|------------------------------------------------------------------------------|---------------------------|-------------------------|--------------------|
| 26,507,021<br>列 / 1,587 站 / 3.4 GB | 2025-08 ~ 2026-07<br>涵蓋區間（12 個月）<br>「站點停擺 8 小時期間硬填出一條平直的線，模型會把『不變』學成一種真實型態。」 | 44.75%<br>is_observed = 1 | 19.92%<br>avail IS NULL | 4.13%<br>avail = 0 |
|------------------------------------|------------------------------------------------------------------------------|---------------------------|-------------------------|--------------------|

# 零值語意對照

三種零要分清楚 —— 格點層最容易被誤讀的地方，三者長得一樣，意義完全不同。

| 欄位狀態            | 意義                           | 匯出時          |
|-----------------|------------------------------|--------------|
| avail IS NULL   | 沒回報，真缺值                      | JSON null    |
| avail = 0       | 有回報，且真的無車可借（censored demand） | JSON 0       |
| is_observed = 0 | 這格是 carry-forward 填出來的       | 值照出，但不可當評估依據 |

★ 不這樣做會怎樣。把 carry-forward 的格拿去算 MAE 會憑空低估約三成 —— 那些格的答案等於上一格，等於在考已經給過答案的題目。只有 is\_observed = 1 的格能當評估遮罩。

跨層換義 · 同名不同義，跨層讀會出錯

| 表             | is_observed = 1 的意思                        |
|---------------|--------------------------------------------|
| baseline      | 格式守門通過（時間與數值都合法）                           |
| baseline_grid | 該格有真實回報（相對於 carry-forward 填的） ← 只有這個能當評估遮罩 |

# 特徵清單

特徵只有一欄：是否放假。

## 為什麼只出 is\_holiday

- 1 DeepAR 對 30min 頻率**自動加 5 個 time feature**，day-of-week 在內
- 2 星期幾模型本來就知道，重複餵是**浪費維度**
- 3 放不放假是行政院公告的，**日期算不出來** —— 這張表存在的理由就是這一句

為什麼用 **VIEW** 而非把欄位寫進 **baseline\_grid**。改特徵不必重跑格點化。格點層 3.4 GB、重建需數分鐘，而特徵調整在專案期間發生過多次。

## 天氣為什麼出局 架構限制，不是調參結果

- 1 dynamic feature 推論時要連未來的值一起餵，雨量就得先有**未來 3 小時的實測值**
- 2 目前**找不到來源** —— CWA 逐鄉鎮預報只給降雨機率 %，語意與雨量 mm 不同

這是**架構上的硬限制**，不是調參調不出來 —— 沒有未來雨量的資料源，這個特徵就餵不進去。

```
public.trainset_v = baseline_grid LEFT JOIN dim_calendar ON ts::date = d
                    |                               |
                    |                               |
                    | target · is_observed         | is_holiday (唯一的 dynamic_feat)
                    |                               |
                    |                               |
                    |                               | (WEATHER) 保留接回點，目前不接
```

# 站集合界定

站數不一樣是因為**時間點不一樣**—— 站點持續新增，每個數字都是某個時間點的實況。

| 集合            | 時間點                   | 站數    | 這個數字是什麼                                        |
|---------------|-----------------------|-------|------------------------------------------------|
| train channel | 截至 2026-03-31 (訓練期)   | 1,528 | 訓練期內有回報的站，最晚一站首報 2026-03-20                    |
| test channel  | 2026-04 (測試期)         | 1,526 | 測試期內有可評估格點的站；少的 2 站進得了訓練，評估時略過                 |
| 前端主檔 ← 定案     | 2026-05-01 當日         | 1,538 | 前端查得到的就是這批。以 5/1 的站位歷史 CSV 為準，Demo 回放固定停在 5/01 |
| baseline_grid | 2025-08 ~ 2026-07 全窗口 | 1,587 | 19 個月的聯集，不是任何一個時間點的實況                          |

**1,587 與 1,528 差的 59 站是新站**。6 站首次回報落在 2026-04、53 站在 2026-05 之後——訓練期它們還沒有資料可學，不是被篩掉。站開得愈晚，能學的歷史就愈少。

**cat 編號是唯一對照**。由 station\_uid 升冪產生、0-based 連續整數，落檔 cat\_map.csv；meta.json 記 names\_n = 1528 與 names\_sha。model.tar.gz **不含站別名稱**，編號錯位會讓站別 embedding 整批對錯站，且**錯得無聲無息**。

# 匯出格式規格

匯出成**兩個目錄**，一行一條序列。

```
data/sagemaker_demo2604/
  train/train.json.gz      1,528 行      8.5 MB    一站一條
  test/ test.json.gz      181,594 行    19.7 MB   一站 119 條
  cat_map.csv              站別對照
  meta.json                匯出參數與雜湊 (md5_plain / bytes_gz)

{"start": "2025-08-01 00:00:00", "target": [12, 11, null, 9, ...], "cat": [0], "dynamic_feat": [[0, 0, 1, ...]]}
```

| 項目        | 規則（AWS DeepAR 規格）             | 違反的後果                         |
|-----------|-------------------------------|-------------------------------|
| start     | 不可帶時區                         | 解析失敗                          |
| target 缺值 | JSON null                     | 填 0 會被學成「沒車」                  |
| cat       | 0-based 連續整數                  | 只能預測訓練時見過的類別                  |
| channel   | 吃的是 <b>目錄</b> ，會把目錄底下所有檔案都讀進來 | 兩檔放同層會讓 train channel 讀到 test |

# 參數與訓練工作核對

meta.json 的參數已與 SageMaker 訓練工作**逐項核對一致**。

匯出參數 meta.json

| 參數                    | 值                         |
|-----------------------|---------------------------|
| freq                  | 30min                     |
| H (prediction_length) | 6 (= 3 小時)                |
| train_end             | 2026-03-31 23:30          |
| origin_days           | 2026-04-01 ~ 04-30，共 30 天 |
| origin_every          | 12 (每 6 小時一個切點)           |
| n_origins             | 119                       |
| max_hist              | 1200                      |
| dyn / dyn_cols        | 1 / ['is_holiday']        |


解讀這兩個數字前先看 **P16 ④⑤** —— 它們綁定 P14／P15 的切法，且與本地回測不同法，不可並排比較。

訓練工作 2026-09-09 查


| 項目                  | 值                                                      |                            |
|---------------------|--------------------------------------------------------|----------------------------|
| Training job        | youbike-deepar-demo2604-20260831-084604<br>(Completed) |                            |
| 演算法映像               | forecasting-deepar:1 (ap-northeast-1)                  |                            |
| 執行個體                | ml.c5.2xlarge × 1，訓練 1,320 秒                           |                            |
| 模型產物                | model.tar.gz，469 KB                                    |                            |
| 4.5235<br>test:RMSE | 0.1969<br>test:mean_wQuantileLoss                      | 1.7426<br>train:final_loss |

# 訓練／測試時間軸

訓練期 8 個月、測試期 1 個月，兩者不重疊。



TRAIN CHANNEL 1,528 行 = 1,528 站 × 1 條




為什麼不補齊到同一起點。站點上線前補 null，等於告訴模型「這個站當時存在但沒車」，與事實不符 —— 各序列的 start 與長度可以不同，是 DeepAR 官方文件明載的。

Demo 的回放起點為何是 5/01。它落在測試期結束後隔天，與訓練期、測試期都不重疊 —— 回放時看到的每一格，都是模型在訓練與評估階段都沒見過的資料。

# 測試切點與序列結構

一站 119 條 —— 181,594 行 = 1,526 站 × 119 個切點，每條對應一個預測時刻。



為什麼限制 **max\_hist**。不限制的話每條序列都會帶完整 8 個月歷史，181,594 條 × 11,664 格**無法上傳**。ctx 只有 48 格，模型實際看的遠少於 1,200 —— 多帶的部分是給 DeepAR 內部 lag feature 用的（最長 lag 加上 context 再留餘裕）。

站數為何 **train 1,528**、**test 1,526**。差的 2 站在測試期（2026-04）沒有可評估的格點 —— 它們進得了訓練，評估時被略過。SageMaker 評分時只取每條序列**最後 H 格**與預測比對，前面的都是餵給模型的脈絡。

# 資料集適用邊界

五條邊界**全部有實測數字**，引用誤差數字之前要一起講——少講一條就會被過度解讀。

|                                                                                                                                                                                                          |                                                                                                                                                                                                                           |                                                                                                                                     |                                                                                                                                                 |                                                                                                                                                                                           |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div>①</div> <div>回報密度逐月不同</div> <div>is_observed 從 2025-08 的 44.7% 到 2026-02 的 20.9%，2026-04 之後約 64%。</div> <div>破洞的月份刻意保留——DeepAR 原生吃 null，砍掉等於連整段冬季的型態一起丟。</div> <div>代價：全期平均誤差不能代表單月效能，需分月切開看。</div> | <div>②</div> <div>誤差有地板<br/>約 1.5~2 台</div> <div>六月同格對齊，TDX 與主辦兩個官方來源只有 <b>54.06%</b> 完全相同，差 1 台以內 79.27%。</div> <div>原因已查明：取樣時刻不同，時間差中位 158 秒——那兩三分鐘內只要發生一次借還就差 1 台。</div> <div>MAE 到 1.5~2 台已接近噪聲地板，再追更高精度是在擬合雜訊。</div> | <div>③</div> <div>avail = 0<br/>是供給狀態</div> <div>它代表「站上沒車可借」，量不到「有多少人想借卻借不到」。</div> <div>用這份資料估算被壓抑的租借需求會失真（censored demand）。</div> | <div>④</div> <div>誤差數字<br/>綁定回測設定</div> <div>6 小時一個 origin、共 119 個切點、每條序列回看至多 1,200 格。</div> <div>換切點密度或歷史長度，數字會變。引用 MAE / RMSE 時要一併說明切法。</div> | <div>⑤</div> <div>SageMaker 與本地<br/>評估不同法</div> <div>SageMaker 的 test channel 只考每條序列最後 H 個點；本地 train_local.py 是多切點滾動回測。</div> <div>兩邊的 RMSE / wQL 不可並排比較。要比就得拉 endpoint 自己做同樣的滾動回測。</div> |
| <div>94.5%</div> <div>② 該半小時車沒動時，兩源完全相同</div>                                                                                                                                                            | <div>55.0%</div> <div>變動 1 台</div>                                                                                                                                                                                        | <div>21.5%</div> <div>變動 6 台</div>                                                                                                  | <div>47.8%</div> <div>尖峰時段（平均變動 2.97 台）</div>                                                                                                   | <div>158 秒</div> <div>兩源取樣時刻差中位</div>                                                                                                                                                     |